

WORLD IN POCKET · SPECIFICA OPERATIVA · 15 AGOSTO 2026

# Filiera POI Culturali

La catena completa: dagli open data del patrimonio mondiale a POI con indirizzo, perimetro, ingresso calibrato, foto, descrizioni e 4 audioguide — con tutti gli strumenti per ogni stadio e i paesi pronti all'estrazione. Fonti e licenze: vedi l'[Atlante Cataloghi del Patrimonio](#).

---

## Principi non negoziabili

- **Solo fonti gratuite con licenza che permette lo storage permanente** (PD, CC0, CC-BY, OGL, KOGL...). Mai Google/Mapbox per dati da salvare. Attribuzione conservata in `address_source` /metadati.
- **Solo categorie culturali/turistiche**: monumenti, chiese, musei, castelli, archeologia, panorami, gemme. Mai locali/utilità/famiglie.
- **La fonte migliore vince e non si sovrascrive**: entrance OSM > civico > catalogo > Wikidata > geocoder.
- **Batch sempre riprendibili** (checkpoint, idempotenza) e **throttling Supabase** (lezione incidente pm2).

## 0 Fondamenta geometriche *(in corso sulla macchina)*

La base che rende possibile tutto il resto: perimetri degli edifici e geometrie stradali coi nomi delle vie.

**STRUMENTI** · DuckDB (memory\_limit 1-2GB, spill su disco) su planet.osm.pbf a parti da 6GB con sotto-divisione 1GB · `pbf-split.mjs` · watchdog cmd + task pianificato · checkpoint parquet per parte

- **Footprint mondo** (7/15 parti): perimetri + tag entrance → `osm_footprints_world.parquet` . Italia già fatta (308k perimetri, 25.373 POI abbinati, raggi applicati al DB).
- **Road tiles Italia** (parte a footprint finito): estratto Geofabrik 2,07GB, single-pass, **con** `street_name` — prerequisite del matching indirizzo→strada. Output: tile snap-to-path su Storage + parquet strade per il matcher.
- **Road tiles mondo — solo celle POI** (dopo l'Italia): 1,88M POI → 322k celle 0,05° dilatate; way→nodi filtrati per coordinata (two-phase, il per-parte era rotto ed è stato

disattivato).

## 1 Raccolta: indirizzi, dettagli, foto per fonte

Un connettore per fonte, tutti convergenti su un formato unico: (source, source\_id, nome, lat/lon, indirizzo, comune, categoria, descrizione, foto\_url+licenza, wikidata\_id) .

**STRUMENTI** · SPARQL (ArCo MiC, Wikidata paginata per paese/Land, RCE olandese) · dump CSV/XLSX/GeoJSON (Mérimeé, NIAH, NRHP, Austria, Polonia, Fiandre...) · WFS/ArcGIS/Atom (Danimarca, Galles, NHLE, Scozia, Geonorge) · REST/XML API (Corea KHS, K-samsök, Estonia, Diba Barcellona) · DuckDB per parsing/normalizzazione · riproiezione griglie nazionali → WGS84

- **Foto:** Wikimedia Commons via Wikidata P18/P373 (gallerie intere) con attribuzione; NRHP = pubblico dominio; MiC solo schede con licenza foto aperta; Giappone testo sì / foto no. Sempre per URL, mai ricopiate nello Storage.
- **Dettagli:** descrizioni dei cataloghi (NIAH ha già testi architettonici lunghi) = grounding fattuale per le audioguide.
- **Buchi residui di indirizzo:** Overture Places/Addresses (CDLA, via parquet S3 + DuckDB) · OpenAddresses (civici) · **Photon self-hosted** (dump planet ~75-80GB, geocoding/reverse illimitato — si installa quando le pipeline liberano la macchina) · API pubbliche Photon/Nominatim-France solo fair-use.

## 2 Matching coi POI esistenti

**STRUMENTI** · DuckDB (join spaziali + similarità nomi) · pattern M1/M2 già validato sull'Italia (wikidata-first, poi spatial+name, soglia confidenza 0.86) · normalizzazione nomi (abbreviazioni "S."→"San", "G."→nome intero, accenti, articoli)

Chiave primaria di aggancio: **ID Wikidata condiviso** (il POI ce l'ha da OSM, il record del catalogo dalla proprietà-registro). Fallback: distanza < soglia + similarità nome. Ogni match porta con sé la provenienza per l'audit.

## 3 Calcolo ingressi (il cuore dell'accuratezza percepita)

**STRUMENTI** · way\_pts (punti perimetro, già in DuckDB) · road tiles con street\_name · PostGIS/DuckDB spatial (punto del perimetro più vicino a una polilinea)

1. Tag entrance OSM (main > yes > altri) — il dato vero.
2. Nodo civico OSM del POI — spesso è esattamente il portone.

3 **Indirizzo** → **strada**: via dell'indirizzo (stadio 1) normalizzata e cercata tra le strade con

- nome entro ~150m → ingresso = punto del perimetro rivolto verso *quella* strada.  
Errore solo longitudinale, mai sul retro.
- 4. Solo chiese: lato verso piazza/pedonale, altrimenti lato ovest (orientamento liturgico).
- 5. Strada vera più vicina (le classi estratte escludono `service` : niente vicoli di carico/scarico).

4 Scrittura su DB (tutto, con provenienza)

**STRUMENTI** · apply-script Node a blocchi con throttling + file di rollback (pattern apply-italy) · migration 20260815100000\_poi\_footprints\_address.sql (da applicare)

| DATO                              | DESTINAZIONE                                                                                             |
|-----------------------------------|----------------------------------------------------------------------------------------------------------|
| Raggi calibrati (trigger + alert) | shared_pois.geofence_radius / alert_radius                                                               |
| Ingresso (vero o stimato)         | shared_pois.entrance_lat / entrance_lon                                                                  |
| Indirizzo + fonte                 | shared_pois.address / address_source <span>NEW</span>                                                    |
| Perimetro completo                | poi_footprints (PostGIS geom + GeoJSON) <span>NEW</span> — trigger poligonali futuri, footprint su mappa |
| Foto (URL + attribuzione)         | shared_pois.images_json                                                                                  |
| Descrizioni breve/lunga/script    | shared_pois / poi_details                                                                                |

5 Import dei POI nuovi (record non matchati)

**STRUMENTI** · filtro qualità (scarta denominazioni catastali "pp.ed. 509", particelle, schede amministrative) · dedup vs shared\_pois e Overture (nome+distanza) · insert a blocchi service-key

Ogni nuovo POI nasce completo: nome, coordinate, indirizzo, categoria mappata sul nostro set, perimetro se disponibile, foto libera, descrizione breve+lunga (catalogo + AI per la forma), `source` tracciato. Status coerente col flusso esistente (visibile ma marcato per provenienza, mai gemma automatica).

6 Audioguide x4 e voce

STROMENTI · callonaver suoni · con rotazione emittenti gratuite (GNCQ\_L7\_07, GEMINI\_L7\_07, ransoon DeepSeek) · scrittura idempotente in poi\_audioguides (chiave poi\_id+lingua+personaggio) · coda con tetto giornaliero per chiave

- **Testi pre-generati:** IT + EN × Nicky + Dante = 4 per POI, grounding = scheda del catalogo (date e fatti veri, niente allucinazioni).
- **TTS on-demand:** l'MP3 si sintetizza alla prima riproduzione e si cachea per sempre (i caratteri Azure costano; pre-generarli per tutto il mondo sprecherebbe quota su POI mai ascoltati). Pre-TTS solo nei pacchetti offline delle zone top.
- **Priorità di generazione:** Italia → celle a densità turistica → coda lunga on-demand.

Paesi pronti all'estrazione

**ONDA 1** subito, endpoint verificati e licenze pulite · **ONDA 2** pronti, dopo l'Onda 1 · **CONFERMA** bulk ok ma licenza da riconfermare prima del batch

| ONDA            | PAESI                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                | NOTE                                                                                                                |
|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| <b>ONDA 1</b>   | <b>Italia</b> (MiC ArCo + pbf su disco) · <b>Francia</b> (CSV Mérimée già scaricato) · <b>Paesi Bassi</b> · <b>Danimarca</b> · <b>USA</b> (PD, foto incluse) · <b>Corea del Sud</b> (API no-key)                                                                                                                                                                                                                                                                                                                     | Le 6 partenze: licenze perfette, indirizzi nel dato, accesso già testato con chiamate reali                         |
| <b>ONDA 2</b>   | <b>Germania</b> (Wikidata-first ~430k + Amburgo/Berlino/Colonia) · <b>UK</b> (ENG 379k + SCO + WAL + NI) · <b>Irlanda</b> (NIAH) · <b>Austria</b> · <b>Polonia</b> (81k) · <b>Fiandre</b> · <b>Svizzera</b> · <b>Slovenia</b> · <b>Croazia</b> · <b>Svezia</b> · <b>Norvegia</b> · <b>Estonia</b> · <b>Canada</b> · <b>Giappone</b> (CSV a lotti) · <b>Australia</b> (registri statali) · <b>Argentina</b> · <b>Spagna</b> (Wikidata + Barcellona 57k + regioni CC-BY) · <b>UNESCO DataHub</b> (1.273 siti, globale) | Bulk verificati; alcuni richiedono join coordinate (AT, PL) o riproiezione griglie (UK) o reverse geocode (SE, ENG) |
| <b>CONFERMA</b> | Nuova Zelanda · Messico · Brasile · Cile · Colombia · India · Sudafrica · Lituania · Romania · Cechia (share-alike)                                                                                                                                                                                                                                                                                                                                                                                                  | Dati esistono ma licenza da riconfermare (portali con bot-block) o con vincoli (SA/PDF)                             |
| <b>GLOBALE</b>  | <b>Tutto il resto del mondo</b> — Grecia, Ungheria, Cina, Turchia, Israele, Egitto, Marocco, Perù e ogni paese senza registro aperto                                                                                                                                                                                                                                                                                                                                                                                 | Via Wikidata (CC0, con P1435 + proprietà-registro) + OSM + Overture Places + Photon: nessun paese resta a zero      |

**Esclusioni per licenza (mai nel batch):** SIPA portoghese (NC-ND) · Baviera Denkmal-Atlas diretto (ND → si usa il mirror Wikidata) · Castilla y León (NC) · IPIC vallone (no redistribuzione) · canale Syndication UNESCO (chiuso → si usa il DataHub) · geocoding Google/Mapbox (no storage permanente).

## Sequenza di esecuzione

1. **Adesso (leggero, in parallelo alle pipeline):** connettori Onda 1 — SPARQL MiC, parser Mérimée, dump NL/DK, XLSX NRHP, API Corea; Wikidata per-paese. Migration `poi_footprints_address` da applicare (SQL Editor).